รายงานเรื่อง

medical insurance cost information

ที่มา : https://www.kaggle.com/datasets/mosapabdelghany/medical-insurance-cost-dataset

ที่มาและความสำคัญ

ปัญหาด้านสุขภาพเป็นปัญหานึงที่อยู่ในทุกช่วงวัยของมนุษย์ ซึ่งในแต่ละคนจะมีปัญหาสุขภาพที่แต่งต่างกันออกไป ประกันสุขภาพจะมาแก้ปัญหาทางด้านค่าใช้จ่ายเหล่านี้ ดังนั้นปัญหาเกี่ยวกับสุขภาพ และการใช้ชีวิต จึงเป็นปัญหาหลักที่บริษัทประกันจะพิจารณาในการจำหน่ายประกันสำหรับบุคคล

สมมติฐานการวิจัย

จำนวนข้อมูล = 1338 ชุด

ตัวแปรตาม

$Y =$ ค่าใช้จ่ายประกันสุขภาพ

ตัวแปรอิสระ

$X_1 =$ อายุ

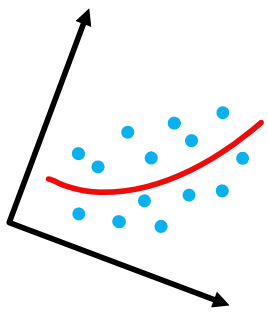
$X_2 =$ Bmi (ดัชนีมวลกาย)

$X_3 =$ จำนวนบุตร

$X_4 =$ ผู้ที่สูบบุหรี่

$X_5 =$ ภูมิภาค

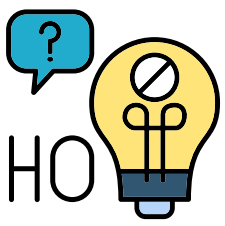
$X_6 =$ เพศ



Linearity

H_0 : ตัวแปร X และ ตัวแปร Y ไม่มีความสัมพันธ์เชิงเส้นตรง

H_1 : ตัวแปร X และ ตัวแปร Y มีความสัมพันธ์เชิงเส้นตรง



Y กับ X_1

```
> cor.test(insurance_clean$age, insurance_clean$charges)

        Pearson's product-moment correlation

data:  insurance_clean$age and insurance_clean$charges
t = 11.954, df = 1308, p-value < 2.2e-16
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.264149 0.361831
sample estimates:
      cor
0.3138201
```

Y กับ X_2

```
> cor.test(insurance_clean$bmi, insurance_clean$charges)

        Pearson's product-moment correlation

data:  insurance_clean$bmi and insurance_clean$charges
t = 7.2834, df = 1308, p-value = 5.604e-13
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.1448109 0.2489225
sample estimates:
      cor
0.1974233
```

Y กับ X_3

```
> cor.test(insurance_clean$children, insurance_clean$charges)

        Pearson's product-moment correlation

data:  insurance_clean$children and insurance_clean$charges
t = 2.498, df = 1308, p-value = 0.01261
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.01479883 0.12260765
sample estimates:
       cor
0.06890441
```



สรุปผล

ตัวแปร Y กับตัวแปร X ทั้งหมดมีความสัมพันธ์เชิงเส้นตรงกัน

p - value < 0.05 จึง ปฏิเสธ H_0

ตัวแปร X และตัวแปร Y มีความสัมพันธ์เชิงเส้นตรงกัน

Independence

$H_0 : \rho = 0$ (ค่าคลาดเคลื่อนมีความสัมพันธ์กัน)

$H_1 : \rho \neq 0$ (ค่าคลาดเคลื่อนไม่มีความสัมพันธ์กัน)

```
> dwtest(model_clean)

        Durbin-Watson test

data:  model_clean
DW = 1.7915, p-value = 0.05985
alternative hypothesis: true autocorrelation is greater than 0
```

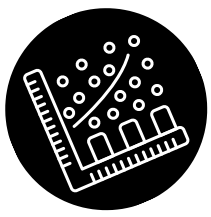
สรุปผล

$H_0 : \rho = 0$ ค่าคลาดเคลื่อนมีความสัมพันธ์

p - value = 0.05985

p - value > 0.05 จึงยอมรับ H_0

ค่าคลาดเคลื่อนมีความสัมพันธ์กัน



วัตถุประสงค์

การศึกษาครั้งนี้เพื่อศึกษาปัจจัยที่มีผลต่อค่าใช้จ่ายประกันสุขภาพของบุคคล เพื่อระบุความสัมพันธ์ระหว่างตัวแปรอิสระ ได้แก่ อายุ เพศ ดัชนีมวลกาย การสูบบุหรี่ จำนวนบุตร และภูมิภาค กับ ค่าใช้จ่ายประกันสุขภาพ เพื่อประกอบการตัดสินใจได้อย่างมีประสิทธิภาพในการวางแผนการตัดสินใจด้านค่าใช้จ่ายที่อาจจะเกิดขึ้นในอนาคต

ประโยชน์ที่ได้รับ

ช่วยให้เราได้เห็นปัจจัยต่างๆที่สามารถส่งผลต่อค่าใช้จ่ายประกันสุขภาพได้แก่ พบว่าอายุมีความสัมพันธ์กับค่าใช้จ่ายเช่น เมื่ออายุมากขึ้น ค่าใช้จ่ายย่อมมีแนวโน้มสูงขึ้น BMI ที่สูงเกินเกณฑ์ก็มีแนวโน้มใช้ค่าใช้จ่ายสูงขึ้น และอื่นๆ

VIF

ตรวจสอบปัญหา Multicollinearity ระหว่างตัวแปรอิสระ หรือ ตัวแปรอิสระมีความสัมพันธ์กันหรือไม่

```
> vif(model_AD)
                GVIF Df GVIF^(1/(2*Df))
age         2.793001  1        1.671227
bmi         1.096877  1        1.047319
children    2.691850  1        1.640686
smoker      1.025184  1        1.012514
region      1.248010  3        1.037615
sex         1.118678  1        1.057676
>
```

สรุปผล

VIF < 10 ตัวแปร X มีความสัมพันธ์กัน



Equality

H_0 : ความแปรปรวนของค่าคลาดเคลื่อนคงที่

H_1 : ความแปรปรวนของค่าคลาดเคลื่อนไม่คงที่

```
> bptest(model_wls)

        studentized Breusch-Pagan test

data:  model_wls
BP = 1.1028, df = 8, p-value = 0.9975
```

สรุปผล

p - value = 0.9975

p - value > 0.05 จึงยอมรับ H_0

ความแปรปรวนของค่าคลาดเคลื่อนคงที่

Normality

H_0 : ตัวแปร Y มีการแจกแจงปรกติ

H_1 : ตัวแปร Y ไม่มีการแจกแจงปรกติ

```
> ad.test(model_AD$residuals)

        Anderson-Darling normality test

data:  model_AD$residuals
A = 0.73592, p-value = 0.05432
```

สรุปผล

ตัวแปร Y มีการแจกแจงปกติ

p - value = 0.05432

p - value > 0.05 จึงยอมรับ H_0

ตัวแปร Y มีการแจกแจงปกติ

ข้อมูลเพิ่มเติม

ดาวน์โหลด

สรุปผล

สมการถดถอย

```
> summary(model_AD)

Call:
lm(formula = log_charges ~ age + bmi + children + smoker + region +
    sex, data = insurance_clean2)

Residuals:
      Min        1Q    Median        3Q       Max
-0.0041489 -0.0016425  0.0001271  0.0014326  0.0041484

Coefficients:
                 Estimate Std. Error  t value Pr(>|t|)
(Intercept)      7.464e+00  2.148e-03 3474.817   <2e-16 ***
age              3.391e-02  3.933e-05  862.231   <2e-16 ***
bmi              7.116e-05  2.506e-05    2.839    0.005 **
children         5.575e-02  2.261e-04  246.602   <2e-16 ***
smokeryes        1.388e+00  1.499e-03  926.066   <2e-16 ***
regionnorthwest -1.884e-02  4.221e-04  -44.629   <2e-16 ***
regionsoutheast -5.384e-02  4.706e-04 -114.405   <2e-16 ***
regionsouthwest -5.439e-02  4.243e-04 -128.185   <2e-16 ***
sexmale         -4.558e-02  3.065e-04 -148.722   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.002084 on 198 degrees of freedom
Multiple R-squared:  0.9999,    Adjusted R-squared:  0.9999
F-statistic: 2.776e+05 on 8 and 198 DF,  p-value: < 2.2e-16
```


1. นางสาว วิภาวี อนันต์ 65050833
2. นาย ธนกฤต ศรีประยูร 67050205
3. นาย ธนาวุฒิ นิยม 67050229
4. นาย นนท์ณพัฒน์ ห้องสวัสดิ์ 67050256
5. นาย ปัณณธร จักษุรัตน์ 67050332
6. นาย พีรพัฒน์ ภัทรวิริยะกิจ 67050404
7. นาย พีรวัส สันตะวา 67050405
8. นายภูติ เสถียรโชค 67050443
9. นาย วราวิชญ์ ศรีวิตตวชิระ 67050509
10. นาย ปิติ วงษ์สกุล 67050977